

# Chap12

## 특이값 분해(Singular Value Decomposition)

### 12.1 로우-랭크(Low-rank) 행렬에 의한 행렬의 근사

#### 12.1.1 로우-랭크 행렬의 이점

Low-rank Assumption은 '어떤 행렬  $M$  을  $M$  보다 더 작은  $rank$  를 가지는 행렬의 곱으로 표현이 가능하다'라는 것을 의미한다. 예를 들어,  $rank$  가 1인 행렬을 생각해 보자. 모든 행들은 1차원 공간에 놓여 있으며,  $\{v\}$  는 이 공간에 대한 기저라고 하자. 행렬의 모든 행은  $v$  의 스칼라배이다.  $u$  를 이러한 스칼라배들의 벡터라고 하면, 이러한 행렬을  $uv^T$  로 나타낼 수 있다. 이러한 표현으로 작은 저장공간으로 행렬을 나타낼 수 있으므로 로우-랭크 행렬의 이점이라 할 수 있다. 즉, 아래의 식과 같이 랭크 1 인  $m \times n$  행렬에 대해 단지  $m + n$  개의 숫자들로 구성할 수 있다.

$$\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}^T = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \\ 3 & 6 & 9 \end{bmatrix}$$

마찬가지로, 랭크가 2인 행렬은 다음과 같이 표현할 수 있다.

$$\begin{bmatrix} | & | \\ u_1 & u_2 \\ | & | \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ - & v_2^T & - \end{bmatrix}$$

그러나, 실제 데이터에서는 행렬 대부분은 로우-랭크가 아니다. 하지만, 종종 로우-랭크의 근사행렬이 거의 원래 행렬 만큼이나 잘 동작한다고 한다.

이번 장에서는 주어진 행렬에 대한 최적의 랭크- $k$  행렬을 찾는 방법에 대해 알아보도록 한다. 이때의 랭크- $k$  행렬은 주어진 행렬에 가장 가까운 행렬이다.

#### 12.1.2 행렬의 $Norm$

주어진 행렬에 가장 가까운 랭크- $k$  행렬을 찾는 문제를 정의하기 위해 행렬들에 대한 거리를 정의하는 것이 필요하다. 벡터들의 경우, 거리는  $norm$  으로 주어지고,  $norm$  은 내적으로 정의된다.  $\mathbb{R}$  상의 벡터들에 대한 내적은 도트곱이고, 벡터의  $norm$  은 그 원소들의 제곱의 합의 제곱근이다.

행렬의  $norm$ 은 행렬  $A$  를 벡터로 해석함으로써 계산할 수 있다.  $m \times n$  행렬은  $mn$ -벡터로 표현할 수 있다.

아래와 같이 행렬  $A$  의  $norm$ 을 계산하는 것을 *프로베니우스(Frobenius) norm* 이라고 한다.

$$\|A\|_F = \sqrt{\sum_i \sum_j A[i, j]^2}$$

*Lemma*:  $A$  의 프로베니우스  $norm$  의 제곱은  $A$  의 행들의 제곱의 합과 동일하다.

- Proof:  $A$  는  $m \times n$  행렬이라 하고,  $A$  를 행벡터로 나타내자.

$$A = \begin{bmatrix} - & a_1 & - \\ & \vdots & \\ - & a_m & - \end{bmatrix}$$

- 각각의 행- $i$  에 대해, 다음과 같이 나타낼 수 있다.

$$\|a_i\|^2 = a_i[1]^2 + a_i[2]^2 + \cdots + a_i[n]^2$$

- 이 식을 프로베니우스  $norm$  의 식에 대입하면 다음과 같다.


$$\begin{aligned} \|A\|_F^2 &= (A[1,1]^2 + A[1,2]^2 + \cdots + A[1,n]^2) + \cdots + (A[m,1]^2 + A[m,2]^2 + \cdots + A[m,n]^2) \\ &= \|a_1\|^2 + \cdots + \|a_m\|^2 \end{aligned}$$

파이썬의 `numpy.linalg.norm()` 에서는 다양한  $norm$  계산을 제공하는데 물론 프로베니우스  $norm$  도 제공한다. 아래의 코드는 `numpy` 모듈을 이용한 프로베니우스  $norm$  을 구하는 코드이다.

```
1 import numpy as np
2
3 A = np.matrix([[1, 0],
4               [0, 1]])
5
6 fro_norm = np.linalg.norm(A, 'fro')
7 print(fro_norm)
8
9 '''출력결과
10 1.4142135623730951
11 '''
```

## 12.2 트롤리 노선 위치 (Trolley-line-location) 문제

9.1 소방차 문제 와 비슷하게 아래의 그림과 같이 벡터  $a_1, \dots, a_m$  으로 표현된  $m$ 개의 주택의 위치에 대해, 트롤리 노선을 어디에다 위치할 것인지를 찾는 문제를 생각해보자.



이 문제의 목적은 트롤리 노선을  $m$  개의 주택에 가능한 가깝게 배치하는 것이다.

각 벡터  $a_i$  는 트롤리 노선으로 부터 자신까지의 거리  $d_i$  를 가진다. 즉, 벡터  $[d_1, \dots, d_m]$  의  $norm$  을 최소화 해야한다. 이 문제는 벡터  $norm$  의 제곱,  $d_1^2 + \dots + d_m^2$  을 최소화하는 것과 동일하다.

### 12.2.1 트롤리 노선 위치 문제에 대한 솔루션

각 벡터  $a_i$  에 대해,  $a_i = a_i^{\parallel v} + a_i^{\perp v}$  라고 나타낼 수 있으며 ( $a_i^{\parallel v}$  는  $v$  에 따른  $a_i$  의 투영,  $a_i^{\perp v}$  는  $v$  에 직교하는 투영) 다음과 같이 쓸 수 있다. 단, 여기서  $v$  는  $Span\{v\}$  를 형성하는 단위  $norm$  벡터( $norm = 1$ )이다.

$$a_1^{\perp v} = a_1 - a_1^{\parallel v}$$

$\vdots$

$$a_m^{\perp v} = a_m - a_m^{\parallel v}$$

피타고라스 정리에 의하면, 다음이 성립한다.

$$\|a_1^{\perp v}\|^2 = \|a_1\|^2 - \|a_1^{\parallel v}\|^2$$

$\vdots$

$$\|a_m^{\perp v}\|^2 = \|a_m\|^2 - \|a_m^{\parallel v}\|^2$$

$a_i^{\perp v}$  는  $a_i$  에서  $Span\{v\}$  까지의 거리이므로, 다음과 같이 나타낼 수 있다.

$$(\text{a}_1 \text{에서 } Span\{v\} \text{까지의 거리})^2 = \|a_1\|^2 - \|a_1^{\parallel v}\|^2$$

⋮

$$(a_m \text{에서 } Span\{v\} \text{까지의 거리})^2 = \|a_m\|^2 - \|a_m^{||v}\|^2$$

위의 식을 수직으로 더하면 다음과 같다.

$$\begin{aligned} \sum_i (a_i \text{에서 } Span\{v\} \text{까지의 거리})^2 &= \|a_1\|^2 + \dots + \|a_m\|^2 - (\|a_1^{||v}\|^2 + \dots + \|a_m^{||v}\|^2) \\ &= \|A\|_F^2 - (\|a_1^{||v}\|^2 + \dots + \|a_m^{||v}\|^2) \end{aligned}$$

위의 12.1.2의 *Lemma*에 의하면  $A$ 는 행들이  $a_1, \dots, a_m$ 인 행렬이다.

$v$ 는 *norm*이 1인 벡터이며,  $a_i^{||v} = \langle a_i, v \rangle$  이므로  $\|a_i^{||v}\|^2 = \langle a_i, v \rangle^2$ 이다. 이를 이용하여 다음과 같이 나타낼 수 있다.

$$\sum_i (a_i \text{에서 } Span\{v\} \text{까지의 거리})^2 = \|A\|_F^2 - (\langle a_1, v \rangle^2 + \langle a_2, v \rangle^2 + \dots + \langle a_m, v \rangle^2)$$

$(\langle a_1, v \rangle^2 + \langle a_2, v \rangle^2 + \dots + \langle a_m, v \rangle^2)$ 는 아래와 같이  $\|Av\|^2$ 로 나타낼 수 있다.

$$\begin{bmatrix} - & a_1 & - \\ & \vdots & \\ - & a_m & - \end{bmatrix} \begin{bmatrix} \\ v \\ \end{bmatrix} = \begin{bmatrix} \langle a_1, v \rangle \\ \vdots \\ \langle a_m, v \rangle \end{bmatrix}$$

$$\|Av\|^2 = (\langle a_1, v \rangle^2 + \langle a_2, v \rangle^2 + \dots + \langle a_m, v \rangle^2)$$

최종적으로 아래와 같은 식을 구할 수 있다.

$$\sum_i (a_i \text{에서 } Span\{v\} \text{까지의 거리})^2 = \|A\|_F^2 - \|Av\|^2$$

따라서, 최적의 벡터  $v$ 는  $\|Av\|^2$ 를 최대화하는 (즉,  $\|Av\|$ 를 최대화하는) 단위벡터이다.

이를 이용하여 트롤리 노선문제에 대한 솔루션은 다음과 같이 pseudo-code로 나타낼 수 있다.

트롤리 노선 문제 솔루션


```
def trolley_line_location(A):
    Given a matrix A, find the vector v1
    minimizing  $\sum_i (a_i \text{에서 } Span\{v\} \text{까지의 거리})^2$ 
    v1 = arg max{ $\|Av\| : \|v\| = 1$ }
    σ1 =  $\|Av_1\|$ 
    return v1
```

---

arg max 표기법은  $\|Av\|$ 의 값이 최대가 되게 하는 것(이 경우 *norm*이 1인 벡터  $v$ )을 의미한다. 이번 장에서는 솔루션을 제시하고 13장에서  $v_1$ 을 근사하는 방법에 대해 공부한다.

*Definition:*  $\sigma_1$  은  $A$ 의 첫 번째 특이값(singular value)이라 하고,  $v_1$  은 첫 번째 오른쪽 특이벡터라 한다.

*Example 12.2.3:*  $A = \begin{bmatrix} 1 & 4 \\ 5 & 2 \end{bmatrix}$  라고 하면, 행렬  $A$ 의 행벡터  $a_1, a_2$ 는  $a_1 = [1, 4], a_2 = [5, 2]$  이다. 이 경우,  $\|Av\|$  을 최대가 되게하는 단위벡터는  $v_1 \approx \begin{bmatrix} 0.78 \\ 0.63 \end{bmatrix}$  이다.  $\sigma_1 = \|Av\|$  은 6.1 이다.



*Theorem:*  $A$  는  $\mathbb{R}$  상의  $m \times n$  행렬이고, 이 행렬의 행들은  $a_1, \dots, a_m$  이라 하자. 이때  $v_1$  은  $A$  의 첫 번째 오른쪽 특이벡터라고 하면,  $\text{Span}\{v_1\}$  은 다음을 최소화하는 1차원 벡터공간  $\mathcal{V}$  이다.

$$(a_1 \text{에서 } \mathcal{V} \text{까지의 거리})^2 + \dots + (a_m \text{에서 } \mathcal{V} \text{까지의 거리})^2$$

*Lemma:* 제곱 거리(squared distances)의 합의 최소값은  $\|A\|_F^2 - \|Av\|^2$  이다.

### 12.2.3 생략

### 12.2.3 최상의 랭크-1 근사

위의 트롤리 노선 위치 문제에 대한 솔루션을 기반으로 하여 주어진 행렬에 대한 최상의 랭크-1 근사를 찾는 문제에 대한 솔루션을 구해보자. 먼저, 랭크-1 근사 문제를 정의하자.

*Rank-one approximation*

- input: 영이 아닌 행렬  $A$
- output: 프로베니우스 norm 에 따라  $A$  에 가장 가까운 랭크-1 행렬  $\tilde{A}$

목적은  $\|A - \tilde{A}\|_F$  을 최소화하는 랭크-1 행렬  $\tilde{A}$ 를 찾는 것이다.

$$\tilde{A} = \arg \min \{ \|A - B\|_F : B \text{는 랭크 1을 가진다} \}$$

어떤 랭크-1 행렬  $\tilde{A}$  가 있다고 하면, 이 행렬은  $A$  에 얼마나 가까운가?  $A$  와  $\tilde{A}$  사이의 제곱 거리를 다음과 같이 나타낼 수 있다.

$$\|A - \tilde{A}\|_F^2 = \|A - \tilde{A} \text{의 행 } 1\|^2 + \cdots + \|A - \tilde{A} \text{의 행 } m\|^2$$

위의 식이 의미하는 바는,  $A$ 에 대한 거리를 최소화하기 위해서는  $\tilde{A}$ 의 각 행이  $A$ 의 대응하는 행에 가능한 가깝도록 되게 선택되어야 한다는 것을 말한다. 또한,  $\tilde{A}$ 는 랭크가 1 이어야 한다. 즉, 어떤 벡터  $v$ 에 대해,  $\tilde{A}$ 의 각 행은  $Span\{v\}$  내에 있어야 한다.

$$\tilde{A} = \begin{bmatrix} - & a_1 \text{에 가장 가까운 } Span\{v\} \text{ 내의 벡터} & - \\ & \vdots & \\ - & a_m \text{에 가장 가까운 } Span\{v\} \text{ 내의 벡터} & - \end{bmatrix}$$

따라서,  $i = 1, \dots, m$ 에 대해, 다음과 같이 나타낼 수 있다.

$$\|A - \tilde{A} \text{의 행 } i\| = a_i \text{에서 } Span\{v\} \text{까지의 거리}$$

$$\|A - \tilde{A}\|^2 = (a_1 \text{에서 } Span\{v\} \text{까지의 거리})^2 + \cdots + (a_m \text{에서 } Span\{v\} \text{까지의 거리})^2$$

## 12.2.4 최상의 랭크-1 근사에 대한 표현

위의 식을 표현하는 더 나은 방법이 있다.  $v$ 를 첫번째 오른쪽 특이벡터  $v_1$ 이라 하고  $a_i$ 에 가장 가까운  $Span\{v_1\}$ 의 벡터는  $a_i^{||v_1}$ 이며, 이것은  $a_i$ 의  $Span\{v_1\}$  상으로의 투영이다. 식  $a_i^{||v_1} = \langle a_i, v_1 \rangle v_1$ 을 사용하여 다음과 같이 나타낼 수 있다.

$$\tilde{A} = \begin{bmatrix} - & \langle a_1, v_1 \rangle v_1^T & - \\ & \vdots & \\ - & \langle a_m, v_1 \rangle v_1^T & - \end{bmatrix}$$

벡터-행렬 곱셈의 선형결합 해석을 사용하여 두 벡터의 외적으로 나타낼 수 있다.

$$\tilde{A} = \begin{bmatrix} \langle a_1, v \rangle \\ \vdots \\ \langle a_m, v \rangle \end{bmatrix} \begin{bmatrix} v_1^T \end{bmatrix}$$

$$\tilde{A} = \begin{bmatrix} Av_1 \end{bmatrix} \begin{bmatrix} v_1^T \end{bmatrix}$$

$\sigma_1 = \|Av_1\|$  (첫번째 왼쪽 특이값)라고 하고,  $u_1$ 은  $\sigma_1 u_1 = Av_1$ 을 만족하는  $norm-1$  벡터라고 하면 다음과 같이 쓸 수 있다.

$$\tilde{A} = \sigma_1 \begin{bmatrix} u_1 \\ \vdots \end{bmatrix} \begin{bmatrix} v_1^T & \vdots \end{bmatrix}$$

*Definition:*  $A$ 의 첫 번째 왼쪽 특이벡터(left singular vector)는  $\sigma_1 u_1 = Av_1$ 을 만족하는 벡터  $u_1$ 이다. 여기서,  $\sigma_1$ 은  $A$ 의 첫 번째 특이값이고  $v_1$ 은 첫 번째 오른쪽 특이벡터이다.

*Theorem:*  $A$ 에 대한 최상의 랭크-1 근사는  $\sigma_1 u_1 v_1^T$ 이다. 여기서 여기서,  $\sigma_1$ 은  $A$ 의 첫 번째 특이값이고,  $u_1$ 은 첫 번째 왼쪽 특이벡터이며,  $v_1$ 은 첫 번째 오른쪽 특이벡터이다.

*Example 12.2.12:* Example 12.2.3에서 보았듯이, 행렬  $A = \begin{bmatrix} 1 & 4 \\ 5 & 2 \end{bmatrix}$ 에 대해, 첫 번째 오른쪽 특이벡터는

$v_1 \approx \begin{bmatrix} 0.78 \\ 0.63 \end{bmatrix}$ 이고, 첫 번째 특이값  $\sigma_1$ 은 약 6.1이다. 첫 번째 왼쪽 특이벡터는  $u_1 \approx \begin{bmatrix} 0.54 \\ 0.84 \end{bmatrix}$ 이며, 이것은  $\sigma_1 u_1 = Av_1$ 임을 의미한다.

$$\begin{aligned} \tilde{A} &= \sigma_1 u_1 v_1^T \\ &\approx 6.1 \begin{bmatrix} 0.54 \\ 0.84 \end{bmatrix} \begin{bmatrix} 0.78 & 0.63 \end{bmatrix} \\ &\approx \begin{bmatrix} 2.6 & 2.1 \\ 4.0 & 3.2 \end{bmatrix} \end{aligned}$$

$$\begin{aligned} A - \tilde{A} &= \begin{bmatrix} 1 & 4 \\ 5 & 2 \end{bmatrix} - \begin{bmatrix} 2.6 & 2.1 \\ 4.0 & 3.2 \end{bmatrix} \\ &\approx \begin{bmatrix} -1.56 & 1.93 \\ 1.00 & -1.23 \end{bmatrix} \end{aligned}$$

따라서,  $A - \tilde{A}$ 의 제곱 프로베니우스 norm은 아래와 같다.

$$1.56^2 + 1.93^2 + 1^2 + 1.23^2 \approx 8.7$$

## 12.2.5 가장 가까운 1차원 아핀공간

12.2에서 트롤리 노선 문제를 정의할 때, 트롤리 노선은 원점을 지나간다고 규정하였다. 이러한 규정을 정의한 이유는 트롤리 노선 문제를 가장 가까운 1차원 벡터공간을 찾는 문제에 대응시키기 위함이었다. 이러한 1차원 벡터공간은 원점을 지나가는 직선이다. 4.5에서 배운 아핀공간 정의에 의하면 임의의 직선(반드시 원점을 지날 필요는 없음)은 아핀공간(Affine space)이다.


트롤리 노선 문제 솔루션을 적용하여 가장 가까운 1차원 아핀공간을 찾을 수 있다. 주어진 점  $a_1, \dots, a_m$ 에 대해, 점  $\bar{a}$ 를 선택하고, 다음에  $\bar{a}$ 를 빼주어 각 입력 점들을 평행이동하면 다음과 같다.

$$a_1 - \bar{a}, \dots, a_m - \bar{a}$$

이러한 평행이동된 점들에 가장 가까운 1차원 벡터공간을 찾고, 그 다음에  $\bar{a}$ 를 더하여 찾은 벡터공간을 평행이동한다. 즉 주어진 점  $a_1, \dots, a_m$ 을  $\bar{a}$ 만큼 빼주어 평행이동시킨 다음 원점을 지나가는 가장 가까운 1차원 벡터공간을 찾고, 그리고 다시  $\bar{a}$ 만큼 평행이동한 것이 바로 가장 가까운 아핀공간이 된다. 이러한 가장 가까운 아핀공간을 찾는 것은 어떠한  $\bar{a}$ 를 설정하느냐에 따라 다르다.  $\bar{a}$ 의 가장 최상의 선택은 입력 점들  $a_1, \dots, a_m$ 의 센트로이드(centroid)이다.

$$\bar{a} = \frac{1}{m}(a_1 + \dots + a_m)$$

주어진 점들의 센트로이드를 찾은 다음, 그 센트로이드를 빼주어 주어진 점들을 평행이동하는 것을 점들에 대한 *센터링* (*centering*)이라고 한다.



## 12.3 가장 가까운 차원 - $k$ 벡터공간

12.2의 트롤리 노선 위치 문제를 더 높은 차원으로 일반화하면 다음과 같다.

*closest low-dimensional subspace:*

- *input:* 벡터  $a_1, \dots, a_m$  과 양의 정수  $k$
- *output:* 다음을 최소화 하는  $k$ -차원 벡터공간  $\mathcal{V}_k$ 에 대한 기저  $\rightarrow \sum_i (a_i \text{에서 } \mathcal{V}_k \text{ 까지의 거리})^2$

트롤리 노선 문제는  $k = 1$  인 단순히 특수한 경우이며, 1차원 벡터공간에 대한 기저를 찾는다.

### 12.3.1 특이값 및 특이벡터를 찾는 *Gedanken* 알고리즘

이 알고리즘의 일반화는 *정규직교* 기저를 찾는 것이다. 이터레이션  $i$  에서, 선택된 벡터  $v$  는  $\|Av\|$  을 최대가 되게 하는 것이며, 이 벡터는 이전에 선택된 모든 벡터들에 직교한다.

- $v_1$ 은  $\|Av\|$  을 최대가 되게 하는  $norm-1$  벡터  $v$
- $v_2$ 는  $v_1$ 에 직교하며  $\|Av\|$  을 최대가 되게하는  $norm-1$  벡터  $v$
- $v_3$ 은  $v_1$  및  $v_2$ 에 직교하며  $\|Av\|$ 을 최대가 되게하는  $norm-1$  벡터  $v$
- $\vdots$

다음은 이 알고리즘에 대한 의사코드이다.



Given an  $m \times n$  matrix  $A$ , find vectors  $\mathbf{v}_1, \dots, \mathbf{v}_{\text{rank } A}$  such that, for  $k = 1, 2, \dots, \text{rank } (A)$ , the  $k$ -dimensional subspace  $\mathcal{V}$  that minimizes  $\sum_i (\text{distance from row } i \text{ of } A \text{ to } \mathcal{V}_k)^2$  is  $\text{Span} \{ \mathbf{v}_1, \dots, \mathbf{v}_k \}$

```
def find_right_singular_vectors(A):
    for i = 1, 2, ...
         $\mathbf{v}_i = \arg \max \{ \|A\mathbf{v}\| : \|\mathbf{v}\| = 1, \mathbf{v} \text{ is orthogonal to } \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{i-1} \}$ 
         $\sigma_i = \|A\mathbf{v}_i\|$ 
    until  $A\mathbf{v} = \mathbf{0}$  for every vector  $\mathbf{v}$  orthogonal to  $\mathbf{v}_1, \dots, \mathbf{v}_i$ 
    let  $r$  be the final value of the loop variable  $i$ .
    return  $[\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r]$ 
```

*Definition:* 벡터  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$  은  $A$ 의 오른쪽 특이벡터이고, 대응하는 실수  $\sigma_1, \sigma_2, \dots, \sigma_r$  은  $A$ 의 특이값들이다.

### 12.3.2 특이값 및 오른쪽 특이벡터들의 성질

위의 12.3.1 에서 다음과 같은 성질을 알 수 있다.

*Proposition:* 오른쪽 특이벡터들은 정규직교(orthonormal) 한다.

*Example 12.3.4:* Example 12.2.3 과 12.2.6 의 행렬  $A = \begin{bmatrix} 1 & 4 \\ 5 & 2 \end{bmatrix}$  를 다시 보자. 첫 번째 오른쪽 특이벡터는

$\mathbf{v}_1 \approx \begin{bmatrix} 0.78 \\ 0.63 \end{bmatrix}$  이고, 첫 번째 특이값  $\sigma_1 \approx 6.1$  이다. 두 번째 오른쪽 특이벡터는  $\begin{bmatrix} 0.78 \\ 0.63 \end{bmatrix}$  에 직교하는 벡터들 중에서 선택되어야 한다. 따라서, 두 번째 오른쪽 특이벡터는  $\begin{bmatrix} 0.63 \\ -0.78 \end{bmatrix}$  이고 대응하는 특이값  $\sigma_2 \approx 2.9$  이다.

벡터  $\mathbf{v}_1$  과  $\mathbf{v}_2$  는 직교한다. 위의 예제에서  $\sigma_2 < \sigma_1$  인 이유는 두 번째 최대화는 더 작은 후보 집합에 대해 수행되므로 첫 번째 값보다 더 클 수 없다.

벡터  $\mathbf{v}_1$  과  $\mathbf{v}_2$  는 직교하고 영이 아니므로, 두 벡터는 선형독립이고  $\mathbb{R}^2$  를 생성한다.

*Proposition:* 특이값들은 음수가 아니며 내림차순(descending order)이다.

- *Proof:* 각 특이값은 벡터의 *norm*이므로 음수가 될 수 없다. 각  $i > 1$  에 대해,  $\mathbf{v}_i$  가 선택되는 벡터들의 집합은  $\mathbf{v}_{i-1}$  이 선택된 벡터들의 집합의 부분집합이다. 따라서, 이터레이션  $i$ 에서의 최대값은 이터레이션  $i - 1$ 에서의 최대값 보다 클 수 없다. 즉,  $\sigma_i \leq \sigma_{i-1}$  이다.

*Lemma:*  $A$  의 모든 행은 오른쪽 특이벡터의 생성에 속한다.

- *Proof:*  $\mathcal{V} = \text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$  이라 하자.  $\mathcal{V}^\circ$ 는  $\mathcal{V}$ 의 소멸자(annihilator)라고 하고,  $\mathcal{V}^\circ$ 는  $\mathcal{V}$ 에 직교하는 벡터들로 구성된다(10.6.4 참고).  $\mathcal{V}^\circ$ 에 속하는 임의의 벡터  $\mathbf{v}^\circ$ 에 대해 곱  $A\mathbf{v}^\circ$ 는 영벡터이다. 따라서,  $A$ 의 행들은  $\mathbf{v}^\circ$ 에 직교한다. 이 의미는  $(\mathcal{V}^\circ)^\circ = \mathcal{V}$ 이므로  $A$ 의 행들이  $\mathcal{V}$ 에 속한다는 것을 보여준다.

### 12.3.3 특이값 분해

12.3.2의 Lemma에 따르면  $A$ 의 각 행  $a_i$  는 오른쪽 특이벡터들의 선형결합이다.

$$a_i = \sigma_{i1} v_1 + \cdots + \sigma_{ir} v_r$$

$v_1, \dots, v_r$  은 정규직교하므로,  $j$  번째 항  $\sigma_{ij} v_j$  는  $j$  번째 오른쪽 특이벡터  $v_j$  에 따른  $a_i$  의 투영이고 그 계수  $\sigma_{ij}$  는  $a_i$  와  $v_j$  의 내적이다.

$$a_i = \langle a_i, v_1 \rangle v_1 + \cdots + \langle a_i, v_r \rangle v_r$$

벡터-행렬 곱셈의 도트곱 정의를 사용하여 다음과 같이 표현할 수 있다.

$$a_i = [\langle a_i, v_1 \rangle \quad \cdots \quad \langle a_i, v_r \rangle] \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}$$

위의 식을 이용하여 행렬  $A$  를 행렬-행렬 곱으로 표현할 수 있다.

$$\begin{bmatrix} - & a_1^T & - \\ - & a_2^T & - \\ & \vdots & \\ - & a_m^T & - \end{bmatrix} = \begin{bmatrix} \langle a_1, v_1 \rangle & \cdots & \langle a_1, v_r \rangle \\ \langle a_2, v_1 \rangle & \cdots & \langle a_2, v_r \rangle \\ & \vdots & \\ \langle a_m, v_1 \rangle & \cdots & \langle a_m, v_r \rangle \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}$$

위의 방정식을 더 간단하게 나타낼 수 있다. 우변의 첫 번째 행렬의  $j$  번째 열은 다음과 같다.

$$\begin{bmatrix} \langle a_1, v_j \rangle \\ \langle a_2, v_j \rangle \\ \vdots \\ \langle a_m, v_j \rangle \end{bmatrix}$$

이것은 선형결합의 도트곱 정의에 의해  $Av_j$  이다.

*Definition:*  $\sigma_j u_j = Av_j$  를 만족하는 벡터  $u_1, u_2, \dots, u_r$  은  $A$  의 왼쪽 특이벡터(left singular vectors)이다.

*Proposition:* 왼쪽 특이벡터들은 정규직교이다.

왼쪽 특이벡터의 정의를 사용하여  $\sigma_j u_j$  를  $Av_j$  에 대입하면 다음과 같다.

$$\begin{bmatrix} A \\ \\ \end{bmatrix} = \begin{bmatrix} | & & | \\ \sigma_1 u_1 & \cdots & \sigma_r u_r \\ | & & | \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}$$

마지막으로,  $\sigma_1, \dots, \sigma_r$  을 대각행렬(diagonal matrix)로 분리하면 다음 방정식을 얻는다.

$$\begin{bmatrix} & & \\ & A & \\ & & \end{bmatrix} = \begin{bmatrix} | & & | \\ u_1 & \cdots & u_r \\ | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}$$

*Definition*: 행렬  $A$ 의 특이값 분해  $A$ 의 인수분해  $A = U\Sigma V^T$ 이다. 여기서, 행렬  $U, \Sigma, V$ 는 다음 세 가지 성질을 가진다.

- Property S1:  $\Sigma$ 는 대각행렬이고 그 원소들  $\sigma_1, \dots, \sigma_r$ 은 양수이고 내림차순이다.
- Property S2:  $V$ 는 열-직교행렬이다.
- Property S3:  $U$ 는 열-직교행렬이다.

*Theorem*:  $\mathbb{R}$  상의 모든 행렬  $A$ 는 특이값 분해(SVD)를 가진다.

특이값 분해는 전치에 대해 대칭성이 있다. 행렬곱의 전치의 성질에 의하면 다음이 성립한다.

$$\begin{aligned} A^T &= (U\Sigma V^T)^T \\ &= V\Sigma^T U^T \\ &= V\Sigma U^T \end{aligned}$$

위의 식에서  $\Sigma$ 의 전치행렬은  $\Sigma$  자신이다. 따라서,  $A^T$ 의 SVD는  $A$ 의 SVD에서  $U$ 와  $V$ 를 바꾸면 된다.

### 12.3.4 가장 가까운 $k$ -차원 공간을 찾는 데 오른쪽 특이벡터 사용하기

*Lemma*:  $v_1, \dots, v_k$ 는 벡터공간  $\mathcal{V}$ 에 대한 정규직교 벡터 기저라고 하면,

$$(a_1 \text{에서 } \mathcal{V} \text{까지의 거리})^2 + \dots + (a_m \text{에서 } \mathcal{V} \text{까지의 거리})^2$$

은  $\|A\|_F^2 - \|Av_1\|^2 - \|Av_2\|^2 - \dots - \|Av_k\|^2$ 이다.

- Proof: 행렬  $A$ 의 각 벡터  $a_i$ 에 대해,  $a_i = a_i^{\parallel \mathcal{V}} + a_i^{\perp \mathcal{V}}$ 라고 표현하자. 피타고라스 정리에 의하면,  $\|a_i^{\perp \mathcal{V}}\|^2 = \|a_i\|^2 - \|a_i^{\parallel \mathcal{V}}\|^2$ 이다. 그러므로 제곱 거리의 합은 다음과 같다.

$$\left( \|a_1\|^2 - \|a_1^{\parallel \mathcal{V}}\|^2 \right) + \dots + \left( \|a_m\|^2 - \|a_m^{\parallel \mathcal{V}}\|^2 \right)$$

- 위의 식은 아래와 동일하다.

$$\left( \|a_1\|^2 + \dots + \|a_m\|^2 \right) - \left( \|a_1^{\parallel \mathcal{V}}\|^2 + \dots + \|a_m^{\parallel \mathcal{V}}\|^2 \right)$$

- 위의 식에서 첫 번째 합  $\|a_1\|^2 + \dots + \|a_m\|^2$ 은  $\|A\|_F^2$ 와 동일하다. 두 번째 합은 다음과 같다.

$$\begin{aligned}
& \|a_1^{\|\mathcal{V}\|}\|^2 + \cdots + \|a_m^{\|\mathcal{V}\|}\|^2 \\
&= \left( \|a_1^{\|v_1\|}\|^2 + \cdots + \|a_m^{\|v_k\|}\|^2 \right) + \cdots + \left( \|a_m^{\|v_1\|}\|^2 + \cdots + \|a_m^{\|v_k\|}\|^2 \right) \\
&= \left( \langle a_1, v_1 \rangle^2 + \cdots + \langle a_1, v_k \rangle^2 \right) + \cdots + \left( \langle a_m, v_1 \rangle^2 + \cdots + \langle a_m, v_k \rangle^2 \right)
\end{aligned}$$

- 위의 내적을 다시 정리하면 최종적으로 다음과 같다.

$$\left( \langle a_1, v_1 \rangle^2 + \cdots + \langle a_1, v_k \rangle^2 \right) + \cdots + \left( \langle a_m, v_1 \rangle^2 + \cdots + \langle a_m, v_k \rangle^2 \right) = \|Av_1\|^2 + \|Av_2\|^2 + \cdots + \|Av_k\|^2$$

*Theorem:*  $A$  는  $m \times n$  행렬이라 하고  $a_1, \dots, a_m$  은 이 행렬의 행이라 하자.  $v_1, \dots, v_r$  은 이 행렬의 오른쪽 특이벡터들이라 하고,  $\sigma_1, \dots, \sigma_r$  은 특이벡터들에 대응하는 특이값이라 하자. 임의의 양의 정수  $k \leq r$  에 대해,  $Span\{v_1, \dots, v_k\}$  은  $k$ -차원 벡터공간  $\mathcal{V}$  이며 이것은 다음을 최소화한다.

$$(a_1 \text{에서 } \mathcal{V} \text{ 까지의 거리})^2 + \cdots + (a_m \text{에서 } \mathcal{V} \text{ 까지의 거리})^2$$

즉, 제곱 거리의 합의 최소값은  $\|A\|_F^2 - \|Av_1\|^2 - \|Av_2\|^2 - \cdots - \|Av_k\|^2 = \|A\|_F^2 - \sigma_1^2 - \sigma_2^2 - \cdots - \sigma_k^2$  이다.

- Proof: 공간  $\mathcal{V} = Span\{v_1, \dots, v_k\}$  에 대한 제곱 거리의 합은 아래와 같다.

$$\|A\|_F^2 - \sigma_1^2 - \sigma_2^2 - \cdots - \sigma_k^2 \longrightarrow (1)$$

- 이값이 최소값임을 증명하기 위해서는 임의의 다른  $k$ -차원 벡터공간  $\mathcal{W}$  가 더 작지 않은 제곱의 합이 된다는 것을 보여줘야 한다. 임의의  $k$ -차원 벡터공간  $\mathcal{W}$  는 정규직교 기저를 가지며,  $w_1, \dots, w_k$  는 이러한 기저라고 하자. 이 기저 벡터들을 위의 Lemma에 적용하면  $a_1, \dots, a_m$  에서  $\mathcal{W}$  까지의 제곱 거리들의 합을 구할 수 있다.

$$\|A\|_F^2 - \|Aw_1\|^2 - \|Aw_2\|^2 - \cdots - \|Aw_k\|^2 \longrightarrow (2)$$

- $\mathcal{V}$  가 가장 가깝다는 것을 보여주기 위해, 식 (2)의 값이 식 (1)의 값보다 작지 않다는 것을 아래와 같이 보여줘야 한다.

$$\|Aw_1\|^2 + \|Aw_2\|^2 + \cdots + \|Aw_k\|^2 \leq \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_k^2$$

- 간단하게 하기 위해, 열들이  $w_1, \dots, w_k$  인 행렬 다음과 같이  $W$ 를 사용하여 나타내자.

$$\|AW\|_F^2 = \|Aw_1\|^2 + \|Aw_2\|^2 + \cdots + \|Aw_k\|^2$$

- 행렬  $A$  는  $A = U\Sigma V^T$  로 인수분해 될 수 있다. 여기서,  $U$  와  $V$  는 열-직교이고  $\Sigma$  는 대각행렬이다.  $\|AW\|_F^2 = \|U\Sigma V^T W\|_F^2$  이다. 이제,  $i = 1, \dots, k$  에 대해,  $v_i$  의  $\mathcal{W}$  상으로의 투영을 생각해 보자.

$$v_i = v_i^{\|\mathcal{W}\|} + v_i^{\perp \mathcal{W}}$$

- 위의 식에서 우변의 두 벡터들은 직교하므로 피타고리스 정리에 의해 다음이 성립한다.

$$\|v_i\|^2 = \|v_i^{\|\mathcal{W}\|}\|^2 + \|v_i^{\perp \mathcal{W}}\|^2$$

- $\|v_i^{||\mathcal{W}}\|^2 \leq \|v_i\|^2 = 1$ 이다.  $x_i$ 는  $v_i^{||\mathcal{W}}$ 의  $w_1, \dots, w_k$ 에 대한 좌표표현이라고 하자. 그렇게 되면,  $v_i^{||\mathcal{W}} = Wx_i$ 이다.  $W$ 는 열-직교이므로,  $\|Wx_i\| = \|x_i\|$ 이므로,  $\|x_i\|^2 \leq 1$ 이다.
- $w_1, \dots, w_k$ 는 정규직교이므로 다음과 같이 쓸 수 있다.

$$x_i = [\langle v_1, w_1 \rangle, \langle v_2, w_2 \rangle, \dots, \langle v_i, w_k \rangle]$$

- 이 벡터는 행렬-행렬 곱셈의 벡터-행렬 정의 및 벡터-행렬 곱셈의 도트곱 정의에 의해  $V^T W$ 의 행  $i$ 이다.

$$\begin{aligned} \|\Sigma V^T W\|^2 &= \sigma_1^2 \|V^T W \text{의 행 } 1\|^2 + \dots + \sigma_k^2 \|V^T W \text{의 행 } m\|^2 \\ &= \sigma_1^2 \|x_1\|^2 + \dots + \sigma_k^2 \|x_k\|^2 \\ &\leq \sigma_1^2 + \dots + \sigma_k^2 \end{aligned}$$

### 12.3.5 $A$ 에 대한 최상의 랭크- $k$ 근사

12.2.4에서 보았듯이,  $A$ 에 대한 최상의 랭크-1 근사는  $\sigma_1 u_1 v_1^T$ 이다. 그렇다면 이것을 일반화해보자.

*Theorem:*  $k \leq \text{rank} A$ 에 대해,  $A$ 의 최상의 랭크- $k$  근사는 다음과 같다.

$$\tilde{A} = \sigma_1 u_1 v_1^T + \dots + \sigma_k u_k v_k^T$$

이때,  $\|A - \tilde{A}\|_F^2 = \|A\|_F^2 - \sigma_1^2 - \sigma_2^2 - \dots - \sigma_k^2$ 이다.

- Proof:

$$\|A - \tilde{A}\|_F^2 = \|A - \tilde{A} \text{의 행 } 1\|^2 + \dots + \|A - \tilde{A} \text{의 행 } m\|^2$$

- $\tilde{A}$ 가  $k$ 보다 작거나 같은 랭크를 가지기 위해서는 차원  $k$ 의 어떤 벡터공간  $\mathcal{V}$ 에  $\tilde{A}$ 의 모든 행이 속해야 한다. 벡터공간  $\mathcal{V}$ 에 대한  $\tilde{A}$ 의 최상의 선택은 다음과 같다.

$$\tilde{A} = \begin{bmatrix} - & a_1 \text{에 가장 가까운 } \mathcal{V} \text{에 속하는 벡터} & - \\ & \vdots & \\ - & a_m \text{에 가장 가까운 } \mathcal{V} \text{에 속하는 벡터} & - \end{bmatrix}$$

$$\|A - \tilde{A}\|^2 = (a_1 \text{에서 } \mathcal{V} \text{까지의 거리})^2 + \dots + (a_m \text{에서 } \mathcal{V} \text{까지의 거리})^2$$

- 12.3.4의 Theorem에 의하면,  $\mathcal{V}$ 까지의 제곱 거리들의 합을 최소화하기 위해서는  $\mathcal{V}$ 가 첫  $k$ 개 오른쪽 특이벡터들의 생성이 되어야 하고, 그 제곱 거리들의 합은  $\|A\|_F^2 - \sigma_1^2 - \sigma_2^2 - \dots - \sigma_k^2$ 이다.
- $i = 1, \dots, m$ 에 대해,  $a_i$ 에 가장 가까운  $\mathcal{V}$ 에 속하는 벡터는  $a_i$ 의  $\mathcal{V}$ 상으로의 투영이고, 다음과 같이 쓸 수 있다.

$$\begin{aligned} a_i \text{의 } \mathcal{V} \text{상으로의 투영} &= a_i \text{의 } v_1 \text{에 따른 투영} + \dots + a_i \text{의 } v_m \text{에 따른 투영} \\ &= \langle a_i, v_1 \rangle v_1 + \dots + \langle a_i, v_k \rangle v_k \end{aligned}$$

- 위의 식을  $a_1, \dots, a_m$ 에 대하여 행렬의 덧셈 정의를 사용하면 다음과 같다.

$$\begin{aligned}\tilde{A} &= \begin{bmatrix} - & \langle a_1, v_1 \rangle v_1 & - \\ & \vdots & \\ - & \langle a_m, v_1 \rangle v_1 & - \end{bmatrix} + \cdots + \begin{bmatrix} - & \langle a_1, v_k \rangle v_k & - \\ & \vdots & \\ - & \langle a_m, v_k \rangle v_k & - \end{bmatrix} \\ &= \sigma_1 \begin{bmatrix} u_1 \end{bmatrix} \begin{bmatrix} v_1 \end{bmatrix} + \cdots + \sigma_k \begin{bmatrix} u_k \end{bmatrix} \begin{bmatrix} v_k \end{bmatrix}\end{aligned}$$

### 12.3.6 최상의 랭크- $k$ 근사에 대한 행렬 형태

위의 식에서 보았듯이,  $A$ 에 대한 최상의 랭크- $k$  근사는  $k$ 개 랭크-1 행렬들의 합이다. 이를 다음과 같이 쓸 수 있다.

$$\tilde{A} = \begin{bmatrix} | & & | \\ u_1 & \cdots & u_r \\ | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}$$

$$\tilde{A} = \tilde{U} \tilde{\Sigma} \tilde{V}^T$$

### 12.3.7 영이 아닌 특이값들의 개수는 $\text{rank } A$ 이다.

12.3.2의 Lemma에 의해, 오른쪽 특이벡터들의 개수  $r$ 은 적어도  $A$ 의 랭크다.

$k = \text{rank } A$ 라고 하면, 이  $k$ 값에 대해,  $A$ 에 대한 최상의 랭크- $k$  근사는  $A$  자신이다. 행렬  $A$ 의 SVD를 다시보자.

$$\begin{bmatrix} A \end{bmatrix} = \underbrace{\begin{bmatrix} | & & | \\ u_1 & \cdots & u_r \\ | & & | \end{bmatrix}}_U \underbrace{\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}}_{V^T}$$

$A$ 의 각 행은  $U\Sigma$ 와  $V^T$ 의 곱에 대응하는 행이다. 따라서, 선형결합에 의해  $A$ 의 각 행은  $V^T$ 의 행들의 선형결합이다. 그리고,  $V^T$ 의 행들은 서로 직교하고 영이 아닌 선형독립이다. 또한, 행들의 랭크는  $\text{rank } A$ 이고 이들의 생성의 차원은  $\text{rank } A$ 이다. 따라서,  $\text{Row } A$ 와  $\text{Row } V^T$ 는 같다.

이와 마찬가지로  $\text{Col } A = \text{Col } U$ 이다. 그 이유는  $A$ 의 각 열은  $U$ 와  $\Sigma V^T$ 의 열과의 곱이고,  $\dim \text{Col } A = \text{rank } A = \dim \text{Col } U$ 이기 때문이다.

*Proposition:*  $A$ 의 특이값 분해  $U\Sigma V^T$ 에서,  $\text{Col } U = \text{Col } A$ 이고  $\text{Row } V^T = \text{Row } A$ 이다.

### 12.3.10 $U$ 는 열-직교임을 증명

12.3.3 의 특이값 분해의 성질 Property S3 에 의하면, 왼쪽 특이벡터들의 행렬  $U$  는 열-직교이다. 그렇다면, 이 성질을 증명해보자.

왼쪽 특이벡터들은  $norm$  이 1이 된다. 이들이 서로 직교한다는 것을 보여야 한다.  $k = 0, 1, 2, \dots, r$  에 대해,  $u_1, \dots, u_k$  는 서로 직교하고 나머지 왼쪽 특이벡터들  $u_{k+1}, \dots, u_r$  과는 직교한다는 것을 귀납법(개별적 사실에서 일반적 원리를 이끌어내는 방법)으로 증명한다.

$$U^\perp = \begin{bmatrix} - & u_1^* & - \\ - & u_2^* & - \\ & \vdots & \\ - & u_r^* & - \end{bmatrix}$$

$$U^\perp AV = \begin{bmatrix} - & u_1^* & - \\ - & u_2^* & - \\ & \vdots & \\ - & u_r^* & - \end{bmatrix} \begin{bmatrix} | & & | & & | \\ | & & | & & | \\ \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_r u_r \\ | & & | & & | \end{bmatrix}$$

위에서  $u_1, \dots, u_k$  는 서로 열-직교이므로 귀납 가설에 의하면, 모든  $i < j < k$  에 대해  $\langle u_i, u_j \rangle = 0$  이다. 이것은  $u_1^* = u_1, u_2^* = u_2, \dots, u_k^* = u_k$  를 의미한다. 따라서, 다음과 같이 쓸 수 있다.

$$U^\perp AV = \begin{bmatrix} - & u_1 & - \\ - & u_2 & - \\ & \vdots & \\ - & u_k & - \\ - & u_{k+1}^* & - \\ & \vdots & \\ - & u_r^* & - \end{bmatrix} \begin{bmatrix} | & & | & & | \\ | & & | & & | \\ \sigma_1 u_1 & \sigma_2 u_2 & \cdots & \sigma_k u_k & \cdots & \sigma_r u_r \\ | & & | & & | \\ | & & | & & | \\ & & & & \\ & & & & \end{bmatrix}$$

$$= \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & \sigma_2 & \cdots & 0 & 0 & 0 \\ & & \ddots & & & \\ 0 & 0 & & \sigma_k & \beta_{k+1} & \cdots & \beta_r \\ 0 & 0 & & 0 & & & \\ & & \vdots & & ? & & \\ 0 & 0 & & 0 & & & \end{bmatrix}$$

위의 식에서 물음표(?)는 귀납단계에서 상관없는 행렬을 의미한다. 귀납 단계는  $u_k$  가 그 뒤에 나오는 모든 벡터들  $u_{k+1}, \dots, u_r$  에 직교한다는 것을 보여줘야 한다. 행렬에서 값  $\beta_{k+1}, \dots, \beta_r$  은  $u_k$  와  $\sigma_{k+1} u_{k+1}, \dots, \sigma_r u_r$  의 내적이다. 이 값이 영임을 보여주고자 한다.

$w$  는 행렬  $U^\perp AV$  의  $k$  번째 행이라 하면,  $w = [0, 0, \dots, \sigma_k, \beta_{k+1}, \dots, \beta_r]$  이고, 다음과 같이 쓸 수 있다.

$$\|w\|^2 = \sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2$$

$V$  는 열-직교행렬이므로, 아래와 같이  $V$  에 의한 곱은  $norm$  을 보존한다. 따라서 다음이 성립한다.

$$\|Vw\|^2 = \sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2$$

$w$ 의 처음  $k-1$ 개 원소들은 영이므로  $Vw$ 는  $V$ 의 열들  $k, k+1, \dots, r$ 의 선형결합이다.  $V$ 의 열들은 서로 직교하므로,  $Vw$ 는  $V$ 의 처음  $k-1$ 열들  $v_1, \dots, v_{k-1}$  각각에 직교한다.  $(U^\perp AV)w$ 의 원소  $k$ 는  $\sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2$ 이며, 다음과 같이 나타낼 수 있다.

$$\|U^\perp AVw\|^2 \geq \sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2$$

$U^\perp$ 는 열-직교행렬이므로,  $U^\perp$ 에 의한 곱은 *norm*을 보존한다.

$$\|AVw\|^2 \geq \sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2$$

따라서, 다음 식을 얻을 수 있다.

$$\frac{\|A(Vw)\|}{\|Vw\|} \geq \frac{\sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2}{\sqrt{\sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2}} = \sqrt{\sigma_k^2 + \beta_{k+1}^2 + \cdots + \beta_r^2}$$

$v$ 는  $Vw$ 를 정규화하여 얻어지는 벡터 즉,  $v = \frac{1}{\|Vw\|} Vw$ 라 하면,  $v$ 는  $v_1, \dots, v_{k-1}$ 에 직교하는 *norm* = 1인 벡터이다. 만약,  $\beta_{k+1}, \dots, \beta_r$  중 하나라도 영이 아니면,  $\|Av\|$ 는  $\sigma_k$ 보다 크게 된다. 그렇게 되면,  $k$ 번째 특이벡터를  $v_1, \dots, v_{k-1}$ 에 직교하는 단위-*norm* 벡터들 중에서  $\|Av\|$ 을 최대가 되게 하는 벡터를 선택하는 것과 모순이 된다. 따라서,  $\beta_{k+1} = 0, \dots, \beta_r = 0$ 임이 증명된다.

## 12.4 특이값 분해 사용하기

### 12.4.1 최소제곱에 SVD 사용하기

지난 10.8.5에서 행렬  $A$ 의  $QR$ 분해는  $\|Ax - b\|$ 를 최소화하는 벡터  $\hat{x}$ 를 찾는 *최소제곱* 문제를 푸는 데 사용할 수 있다는 것을 알아보았다. 하지만  $QR$ 분해는  $A$ 의 열들이 일차독립일 경우에만 적용될 수 있는 문제가 있었다. 이번에는 특이값 분해를 이용해  $A$ 의 열들이 선형독립이 아니어도 최소제곱 문제를 푸는 방법에 대해 살펴본다.

$$V^T \hat{x} = \Sigma^{-1} U^T b$$

$$\Sigma V^T \hat{x} = U^T b$$

$$U \Sigma V^T \hat{x} = U U^T b$$

$$A \hat{x} = U U^T b$$

$U U^T b$ 는  $b$ 의 *ColU* 상으로의 투영  $b^{\text{ColU}}$ 이다.  $\text{ColU} = \text{ColA}$ 이므로  $U U^T b$ 는  $b$ 의 *ColA* 상으로의 투영이다.